

LLM Inference Benchmarking Standards

术语

Request

请求 (Request) 是指测试系统向被测试系统发送的一次生成任务。

System Prompt

系统提示(System Prompt)是预定义的查询或指令, 旨在以更专注和受控的方式引导被测试系统的响应。系统提示可以添加在每个请求 (Request) 输入文本之前, 用于从被测试系统获取更加准确和相关的输出。

Input Token

输入 Token (Input Token) 是向被测试系统发送输入经 Tokenzier 编码后所对应的 Token。输入 Token 在测试过程中需要被计数, 如果单个请求生成的响应包含多个序列, 那么输入Token要对应的多次计数。

Output Token

输出 Token (Output Token) 是指被测试系统针对请求产生的响应所包含的生成序列经 Tokenzier 编码后所对应的 Token。输出 Token 测试过程中需要被计数, 如果单个请求生成的响应包含多个序列, 那么要对所有的输出 Token 进行计数。

Data Sampling Policy

数据采样策略 (Sampling Policy) 为从特定数据集中通过预定义的方法策略构造请求输入Token和所需输出Token的数量。需要固定随机数种子以保证向各个被测试系统发送的请求一致。目前主要为nature、fixed、normal三种采样策略。

1. Nature

自然对话采样指向被测试系统发送请求的输入Token数量和输出Token数量, 为从数据集自然对话中采样所得, 需要对输入token数量和输出token数量大小进行筛选, 以满足被测试系统的要求。

2. Fixed

固定长度采样指向被测试系统发送请求的输入Token数量 (fixed_prompt_len) 和输出Token数量均为固定值大小 (fixed_output_len) 。输入Token须是从大于fixed_prompt_len的对话做截断所得。

3. Normal

正态分布采样指向被测试系统发送请求的输入Token数量和输出Token数量服从正态分布, 需提供输入Token数量和输出Token数量的均值和方差。输入Token须是从大于期望输入Token数量的对话做截断所得。

Concurrent Requests

并发请求数（Concurrent Requests）是指在给定时间点，测试程序已经发出且还未完成的请求数量。测试过程中，测试系统需要将并发请求数维持在指定数值，在测试过程中，当任何请求完成并导致当前实际并发请求数低于指定数值时，测试程序应立即发起额外的请求，以确保实际并发请求数持续保持在指定数值。

Max Concurrent Requests

最大并发请求数（Max Concurrent Requests）指的是测试中需要维持的最高并发请求量。

Ramp-up

递增阶段 (Ramp-up) 是性能测试开始阶段的一个过程，这个过程中并发请求数（Concurrent Requests）需要逐步增加，直至达到预定水平。这一阶段的目标是避免测试一开始就对被测试系统施加过高的负载，这可能会导致系统处于非常规运行状态并影响测试的稳定性和准确性。通过逐渐增加负载，Ramp-up 确保系统能平稳过渡到高负载状态。递增阶段应计入测试总持续时间，递增阶段产生的测试数据也作为最终数据的一部分，与其他数据并不区分。

Ramp-up Period

递增阶段时长（Ramp-up Period）是指递增阶段持续的时间，在递增阶段之内，并发请求数（Concurrent Requests）应按照线性从1增长到最大并发请求数（Max Concurrent Requests），期间的每个单位之间内增加的相同的并发请求数。

Warm-up

预热（Warm-up）是指在正式测试开始之前，通过发送一定量的请求来让被测试系统达到一个稳定的状态。预热阶段应当同正式测试阶段使用相同的最大并发请求数（Max Concurrent Requests）与递增阶段时长（Ramp-up Period）配置，预热阶段发送的请求数量应保证被测试系统可以达到最大并发请求数。

Duration

测试持续时间（Duration）是指在测试正式执行阶段的总时间，该阶段从发出第一个请求的时间点开始，直到最后一个请求完全被处理并收到响应的时间点结束。正式执行阶段不包括 Warm-up，包括 Ramp-up。

Request Throughput

请求吞吐（Request Throughput）是指测试正式执行阶段完成的请求数与 Duration 的比值。

Output Token Throughput

输出 Token 吞吐（Output Token Throughput）是指测试正式执行阶段累计的输出 Token（Output Token）的数量与 Duration 的比值。

Total Token Throughput

总 Token 吞吐（Total Token Throughput）是指测试正式执行阶段累计的输入 Token（Input Token）与输出 Token（Output Token）的数量与 Duration 的比值。

End-to-end Latency

端到端延迟（End-to-end Latency）是指每个请求（Request）从发起到完成生成所经历的时间。如果响应中包含多个序列，每个序列分别统计。端到端延迟需要报告 p25、p50、p75、p90、p95、p99 百分位数以及平均数，平均数为所有端到端延迟的平均值。

TTFT

首 Token 延迟（TTFT/Time To First Token）是指每个请求（Request）从发起到产生第一个 Token 响应所经历的时间。如果响应中包含多个序列，每个序列分别统计。首 Token 延迟需要报告 p25、p50、p75、p90、p95、p99 百分位数以及平均数，平均数为所有首 Token 延迟的平均值。

TPOT

每输出 Token 延迟（TPOT/Time Per Output Token）用于度量响应中生成每个 Token 所需要的时间。计算方式为针对每个序列第一个生成 Token 以外的生成的 Token，该 Token 对应的每输出 Token 延迟为对应序列生成首个 Token 到生成当前 Token 所经历的时间与首个 Token 以外的生成 Token 数量的比值。序列的每输出 Token 延迟为该序列中所有非首个生成 Token 以外的生成 Token 的每输出 Token 延迟的平均值。每输出 Token 延迟需要报告所有序列每输出 Token 延迟的 p25、p50、p75、p90、p95、p99 百分位数以及平均数，平均数为所有序列每输出 Token 延迟的平均值。

数据准备流程

数据准备分为三个阶段，数据下载、数据清洗、数据采样

数据下载

下载 [ShareGPT_V3_unfiltered_cleaned_split.json](#)。

数据清洗

原始的JSON文件包含了94,145个独立的JSON对象，每个对象代表一个样本。这些样本包含两个关键字段：id和会话（conversations）。每个会话由多个对话（conversation）组成，而每个对话又包含来源（from）和值（value）两个字段。

来源字段分为两类：用户（user或human）和智能系统（gpt、chatgpt、bing、bard），分别代表用户的提问（input）和系统的回答（output）。值字段则存储了相应的文本内容。

理想情况下，每组会话的第一个对话的来源字段应为用户输入类型，且整个会话应由用户输入和系统输出交替构成，总对话数为偶数。

然而，数据集中存在一些错误，如非法的来源字段值（例如system）、用户连续提问而系统未回答、系统对单次用户提问给出多次回答，或对话丢失导致会话不是由输入和输出交替构成。

为确保数据清洗后的可复现性，我们采取以下清洗策略：遍历sharegpt数据集中的每个conversations，依次交替取：首个满足“from字段为user或human，且value字段不为空的conversation的value”作为一条input，首个满足“from字段为gpt、chatgpt、bing或bard，且value字段不为空的conversation的value”作为一条output，构造由input和output交替组成的一组对话。当该组对话中的文本条数不为偶数时，即最后一条文本为input类型，则删除该最后一条的input类型的文本。当清洗后一组对话中的对话条数为0时，删除对应的conversations。这样清洗后，样本数量预计从94,145减少至92,802。

数据采样

使用 sharegpt 数据集进行基准测试时，不需要使用数据集中的所有数据，我们使用预先定义的方法从数据集中采样有限个样本来进行评测。应对不同的评估场景，我们提供了三种不同的数据采样方式，分别为 nature、fixed、normal，对应自然采样、固定长度采样、正态分布采样。采样得到的单条样本格式为 (prompt, prompt_len, output_len)。

自然采样（nature）：

自然采样指随机采取指定个样本数量，对每一个样本随机采取一定长度的对话轮次构造一组prompt和output。将第一轮至倒数第二轮的对话的prompt与output拼接到一起作为对话历史，将对话历史与最后一轮的prompt拼接作为该样本的prompt，将该样本的prompt与最后一轮的output拼接作为该样本的prompt_output。自然采样不改变sharegpt里对话中prompt与output的长度，用户配置max_turns、min_prompt_len、min_output_len、max_prompt_len、max_prompt_output_len来限制采样时采集得的一组对话中，包含的对话轮数、最终构造生成的prompt的长度、最终构造生成的output的长度、最终构造生成的prompt与output总长度。

采样流程为：

1. 为numpy设置固定的随机种子
2. 使用np.random.permutation将数据集打乱重排
3. 遍历打乱后数据集中的每一个样本
4. 对每一个样本根据配置max_turns计算可采集的最大对话轮数，turns = min(len(sample) // 2, max_turns)
5. 对每一个样本随机一个采集的对话轮数，selected_turn = np.random.randint(0, turns)
6. 在每一个样本的多轮对话中，顺序遍历用户与智能系统的对话，交替取首个用户提问与系统回答，直至对话轮数满足selected_turn
7. 检查该样本的prompt、output、prompt_output长度是否符合用户配置的限制，如果不符合则删除该样本，如果符合要求则(prompt, len(prompt_tokens), len(prompt_output_tokens)-len(prompt_tokens))为该条采样得到的样本
8. 当满足条件的样本满足用户指定的采样数量，停止采样。

固定长度采样（fixed）：

固定长度采样指随机采取指定个样本数量，构造满足用户配置的指定长度的prompt与output。遍历样本的多轮对话，将每一轮的prompt与output累积拼接直至满足用户配置的prompt长度，如果某样本的多轮对话所有文本长度不满足用户配置的prompt长度，则删除该样本。要求智能系统返回用户指定长度的output。用户配置fixed_prompt_len与fixed_output_len来指定采样生成的样本的prompt与output长度。

采样流程为：

1. 为numpy设置固定的随机种子
2. 使用np.random.permutation将数据集打乱重排
3. 遍历打乱后数据集的每一个样本

4. 在每一个样本的多轮对话中，顺序遍历用户与智能系统的对话，交替取首个用户提问与系统回答进行累积拼接作为该样本的prompt，直至len(prompt_tokens)满足用户配置的fixed_prompt_len，当len(prompt_tokens)大于fixed_prompt_len时，删除多余tokens。
5. (prompt, fixed_prompt_len, fixed_output_len)为该条采样得到的样本。
6. 当满足条件的样本满足用户指定的采样数量，停止采样。

正态分布采样 (normal)：

正态分布采样指随机采取指定个样本数量，构造prompt和output的长度分别符合正态分布的样本。

用户配置 max_seq_len、prompt_len_mean、prompt_len_std、output_len_mean、output_len_std 来限制最大序列长度以及prompt和output的均值和标准差

采样流程为：

1. 为numpy设置固定的随机种子
2. 将每个样本中每轮对话的prompt和output累积拼接，统计每一个样本中所有对话的总长度，按照总长度排序
3. 按照用户配置的prompt_len_mean、prompt_len_std和output_len_mean、output_len_std使用 np.random.normal生成两个需要采样样本数量的列表prompt_len和output_len，并用np rint取整
4. 将prompt_len和output_len按元素相加，按照相加后的结果进行排序，将prompt_len和output_len按照此序列重排
5. 处理边界，如果 prompt_len[i] <= 0，则 prompt_len[i] = 1；如果 prompt_len[i] > max_seq_len，则 prompt_len[i] = max_seq_len - 1；如果 output_len[i] <= 0，则output_len[i] = 1；如果output_len[i] + prompt_len[i] > max_seq_len，则 output_len[i] = max_seq_len - prompt_len[i]；
6. 遍历排序后的数据集中的每个样本，累积拼接该样本下所有对话轮次的prompt和output作为一个prompt，如果该prompt的tokens数大于等于prompt_len[i]，则prompt_tokens[:prompt_len[i]]作为采样得到第i个样本的prompt， output_len[i]作为采样得到第i个样本的output_len；
7. (prompt_tokens[:prompt_len[i]], prompt_len[i], output_len[i])为该条采样得到的样本。
8. 当满足条件的样本满足用户指定的采样数量，停止采样。

测试流程

1. 启动被测试系统的server服务, 提供Stream Generation接口。启动服务时保证机器为完全空闲状态，以使得被测试系统能达到最佳性能。
2. 基于【数据准备流程】选取的对话样本构造输入请求。**需要选取合适的请求数量使得单个系统测试时常为30分钟~60分钟为佳。**
3. 客户端向被测试系统server统一发送Stream Generation请求。分为warm up和benckmark阶段。
 - 3.1 WarmUp 阶段:
向被测试系统逐步发送请求，请求并发量从1线性增加到最大并发度限制。后续维持请求数量为最大并发度大小，直到该阶段请求发送完毕。该阶段结果可供参考，不做记录。
 - 3.2 Benchmark阶段:
向被测试系统逐步发送请求，请求并发量从1线性增加到最大并发度限制。后续维持请求数量为最大并发度大小，直到该阶段请求发送完毕。该阶段结果为正式测试结果，需保存记录。
4. 整理测试结果，本轮测试结束。